

Unit 1

시계열분석 소개

7주차. 시계열분석

학습 내용

- + 시계열이란?
 - Stationarity
- + 시계열 모형
- + 시계열 모형의 특징

학습 목표

- + 시계열의 정상성에 대해 이해하고 설명할 수 있다.

시계열이란?

☑ 시계열의 정의

시계열 시간에 따른 데이터의 series

» 시간 : 독립변수

» 핵심내용 : **Serial dependence**
(내재적 의존성, time-dependent structure)


» 용도 : **예측(forecasting)**

➡ Date Series는 과거의 값에 **의존성**이 있다.

시계열이란?

☑ 시계열의 이론 설명

Stochastic Process



- » 특정 확률과정의 **실현** 또는 **샘플 함수**
- » 시간에 따라 **순차적**으로 생성 된 일련의 **관측 값**
- » **시간에 따른 의존성**(무작위 샘플은 개념이 다름)
- » 관측값의 **시간 간의 거리**는 **동일**하다고 가정(시간상 더 **가까운 값**들에 대한 의존성이 큼)

시계열이란?

☑ 시계열의 이론 설명

Mean Function

$$\mu_t = E[Y_t]$$

Variance Function

$$\sigma_t^2 = \gamma_0 = \text{Var}(Y_t) = E(Y_t - \mu_t)^2 = E(Y_t^2) - \mu_t^2 < \infty$$
$$(\gamma_0 \geq 0)$$

- Autocorrelation Function = Normalized Autocovariance (분산으로)

Stationarity

☑ Stationarity 소개

Stationarity(정주성 또는 정상성)

“ 시계열을 제어하는 확률법칙이
시간에 따라 변하지 않는다.”

➤ 시계열이 통계적으로 균형 상태에 있다는 것을 의미

Stationarity

☑ Strong Stationarity

프로세스가 2개인 경우

$$F_{Y_{t_1}, Y_{t_2}}(y_1, y_2) = F_{Y_{t_1+k}, \dots, Y_{t_2+k}}(y_1, y_2) \text{ for any } t_1, t_2 \text{ and } k.$$

➡ 시간의 거리가 k만큼 변형해도 확률분포가 동일하면 **Second-order-Stationary**

$$F_{Y_{t_1}, \dots, Y_{t_n}}(y_1, \dots, y_n) = F_{Y_{t_1+k}, \dots, Y_{t_n+k}}(y_1, \dots, y_n) \text{ for any } t_1, \dots, t_n \text{ and } k.$$

➡ n개에 대해서 시간의 거리가 달라도 확률분포가 동일하면 **nth-order-Stationary**

Stationarity

☒ Strong Stationarity

강정상성(Strong Stationarity, 강정주성)에서는

평균

➤ 일정함

분산

➤ 일정함

Covariance

➤ 시간에 의존함

Correlation

➤ 시간에 의존함

Stationarity

☒ Weak Stationarity

 **강한 개념의 Stationary는 거의 관측이 안 됨**

➤ **Weak Stationarity**라는 개념을 사용해서 가정

Stationarity

☑ Weak Stationarity

Weak Stationarity

➡ 시계열은 1차 모멘트와 2차 모멘트가
시간 원점의 변화에 영향을 받지 않는 경우
공분산 안정적(Covariance Stationary)이라고 함

» 평균과 분산 : 동일

» Correlation와 Covariance : 시간의 거리에 의존

시계열 분석에 있어서는 **Weak Stationarity**가 stationarity의 개념으로 이용

시계열 모형

☑ White Noise

백색잡음(White Noise)

전도체 내부 전자들의 열에 따른 불규칙한 움직임



주파수 스펙트럼, Frequency 도메인으로 전환하면
흰색 빛과 동일한 Frequency를 가져서
백색잡음이라고 불림

시계열 모형

☑ White Noise

백색잡음(White Noise)

- » 시계열 모형의 제일 마지막 부분의 잔차 또는 Residual로 묘사
- » $E(Y_t) = \mu, Var(Y_t) = \sigma^2$: 고정된 평균과 분산
- » $\gamma_s = 0, s \neq 0$: 자기상관 (Autocorrelation) = 0

☑ White Noise

Gaussian White Noise

» Normal 분포를 따르면서 평균 0, 분산 σ^2 인 Random Variable

Residual

- 모형으로 설명이 안되는 부분
- 제거 불가능
- 모형이 타겟을 완벽하게 설명할 경우 잔차(Residual)은 백색잡음

**완벽한 모형은 불가능,
Residual이 백색잡음으로 나타나기 어려움**

Residual이 White Noise로 **증명**이 된다면 매우 훌륭한 모형

시계열 모형

☑ Auto Regressive

AR (Auto Regressive)

$$\begin{aligned} Y_t &= \mu + \phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p} + \varepsilon_t \\ &= \mu + \sum_{i=1}^p \phi_i Y_{t-i} + \varepsilon_t \end{aligned}$$

과거 p 시점의 데이터까지 의존

시계열 모형

☑ Auto Regressive

**특성방정식의 모든 해가 단위원 외부에 존재할 경우,
AR(p)가 정주성을 지님**

$$\text{AR}(1) \quad |\phi_1| \leq 1$$



Stationarity

» 대부분 1에 가까운, 0.9를 넘는 값

» **Serial Dependence**가 강하고 **Nonstationarity**에 근접

☑ Auto Regressive

AR(p)모형에서 **최적의 p값** 도출 방법

- » **ACF**(Autcovariance Function)
- » **PACF**(Partial Autocovariance Function)
 - 두가지 방법을 통해 시각적으로 파악 가능

☒ Auto Regressive

? Stationarity가 중요한 이유

Nonstationarity

- 통계적 특성을 활용할 수 없어 분석이 불가능
- Stationarity 데이터로 변환해야 함
- Nonstationarity 할 경우 수렴하지 않고 발산

Stationarity를 확보하는 것이 매우 중요

시계열 모형

☑ Moving Average

MA(Moving Average)



잔차의 값으로 함수를 표현하는 것

- » 고정된 평균과 분산을 지님
- » 시간격차 q 까지는 자기공분산 $\neq 0$, 그 이후는 전부 0
- » $MA(q)$ 는 Weak Stationarity 조건을 충족함

시계열 모형

☑ ARMA(p,q) and ARIMA

ARMA(p,q)

AR(p)

+

MA(q)

ARIMA(p,d,q)

AR(p)

+

Integrated

+

MA(q)

시계열 모형

☑ SARIMA

SARIMA

➡ Seasonal ARIMA(p,d,q)

➤ 실물경제 관련 데이터는 대부분 계절성을 지님

예 Monthly Pattern, Weekly Pattern 등

시계열 모형

☑ ARMAX

ARMAX



ARMA + 외생적인 설명변수

- » 외생적인 설명 변수를 추가하여 모형의 설명력 높여줌
- » Multivariate Time-series Analysis 성격을 포함

☑ State Space Model, Kalman Filter

State Space Model & Kalman Filter



State Evolution 프로세스 도입

- » Time-series는 State의 변함에 따라 변동폭이 크거나 또는 안정적인 Series를 Generate함
- » 두 가지 경우를 혼합시켜 놓으면 완전히 다른 두 체제의 Series같지만 설명이 가능
- 변동폭이 큰 시계열을 설명하는 모형으로 많이 활용

시계열 모형

☑ GARCH(p,q)

GARCH(p,q)

(Generalized Autoregressive Conditional Heteroskedasticity)

AR모형

이분산성



시간에 따른 변동성을 모형화하기 위해 도입

Conditional Variance

- » Stock Return 모형에서 많이 활용
- » 수익률 변동성군집현상을 어느 정도 설명
- » 통상 p,q의 값은 GARCH(1,1)

☑ Exponential Moving Average

Exponential Moving Average

(EMA 또는 Exponentially Weighted Average:EWMA)

- » Industry에서 Practice가 많이 되는 모형
- » 시간이 가까우면 가중치를 많이 주고 시간이 멀면 조금만 반영
- » 설명력이 높아 많이 활용

시계열 모형의 특징

☑ Wold's Decomposition Theorem

Wold's Decomposition Theorem

- » 정주성 시계열은 상관관계를 가지지 않는 두 개의 확률과정의 합으로 표현 가능
- » 한 확률과정은 순전히 비확률적(i.e., 확정적) 요소만으로 구성
- » 또 다른 확률 과정은 순전히 확률적 요소만으로 구성

시계열 모형의 특징

☑ Partial Autocovariance

Partial Autocovariance

» 두 변수간의 상관관계 측정 시
모든 변수의 영향을 제거 후 상관관계 측정

예 시간 간격이 3인 PACF일 경우

Y_{t-1} 과 Y_{t-2} 의 영향을 제거한 뒤
 Y_t 와 Y_{t-3} 간 상관관계를 측정

» 시간간격이 1인 경우 ACF 와 PACF는 일치

시계열 모형의 특징

☑ Invertibility Condition

Invertibility Condition

다음 **조건** 충족 시 MA(q) 모형을 $AR(\infty)$ 로 표현 가능

$$1 + \theta_1 z + \theta_2 z^2 + \cdots + \theta_q z^q = 0$$

➤ 이 방정식의 **모든 해가 단위원 외부에 존재**할 때 변환 가능

➡ **Stationarity 조건**을 만족하면
변환이 가능하다는 것을 의미

시계열 모형의 특징

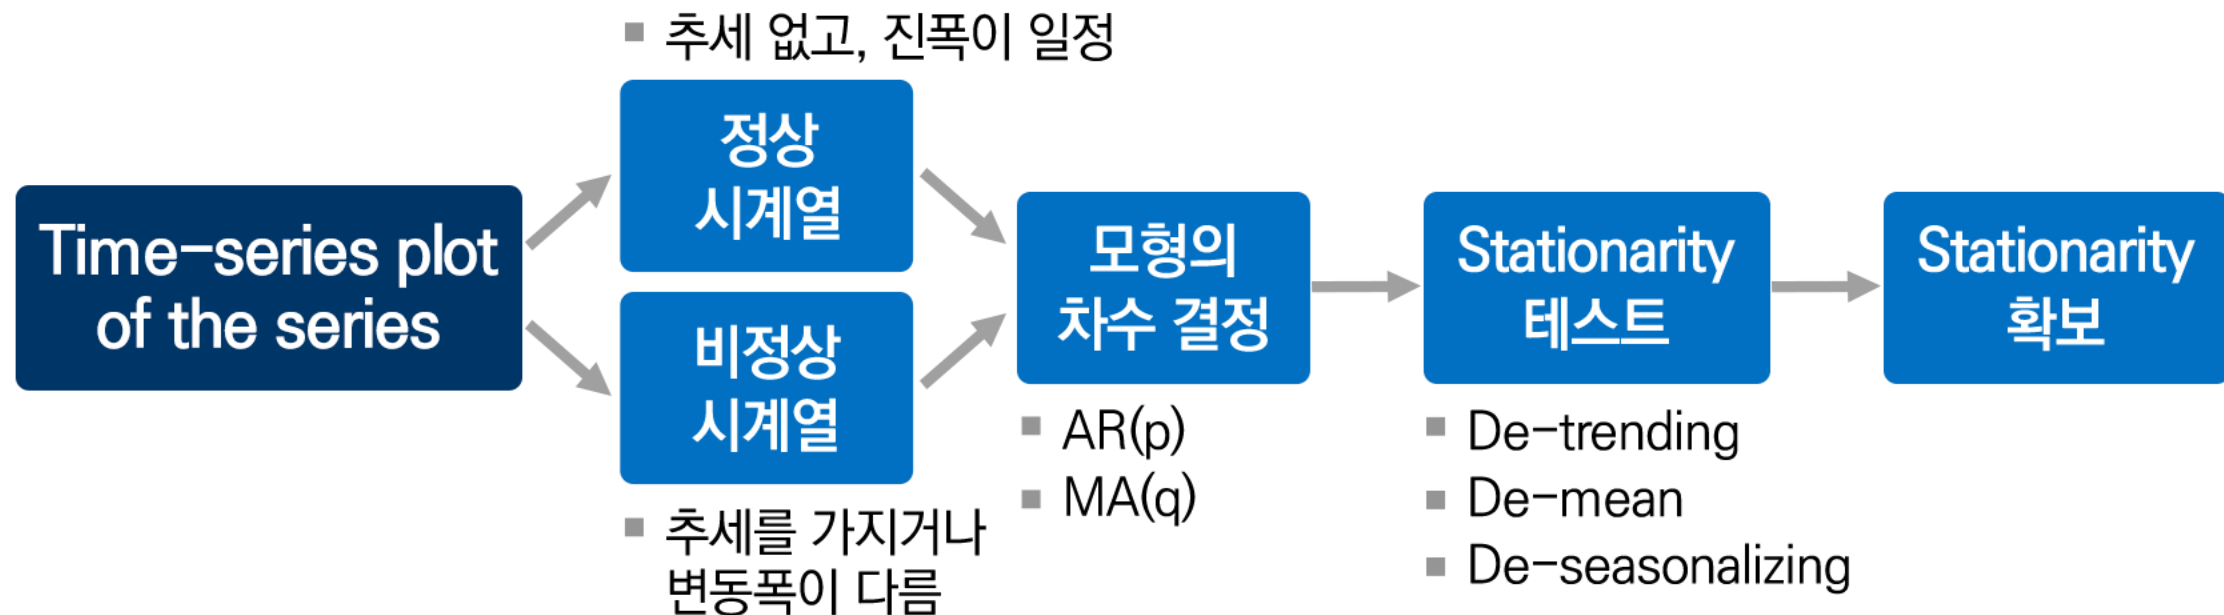
☑ ACF, PACF의 시계열별 특성

| | ACF | PACF |
|-----------|--|--|
| AR(p) | 기하급수적으로 감소 | $PACF(s) \neq 0, s \leq q$ $PACF(s) = 0, s > q$ |
| MA(q) | $ACF(s) \neq 0, s \leq q$ $ACF(s) = 0, s > q$ | 기하급수적으로 감소 |
| ARMA(p,q) | 기하급수적으로 감소 | 기하급수적으로 감소 |

시계열 모형의 특징

✓ 시계열 분석의 순서

1 모형 식별(Model Identification)



시계열 모형의 특징

☑ 시계열 분석의 순서

2 // 모형 Specify

- » AR, MA, 또 다른 GARCH 모형 등

3 // 추정(Estimation)

- » 최대우도법
(Maximum Likelihood Estimation, MLE)
- » 적률추정법
(Method of Moments Estimation, MME)

4 // 모형진단(Diagnostic Checking)

- » Residual error terms
- » Independency of error terms
- » Constant error variance (Homoscedasticity)
- Error Term이 White Noise이면 완벽하고 훌륭한 모형

시계열 모형의 특징

☑ 시계열 분석의 순서

5 예측(Forecasting)

- » 트레이닝셋, 테스트셋, 데이터셋을 구분 후
테스트셋을 통해 예측
- » 여러 가지 척도를 통해 평가

시계열 모형의 특징

☒ Parsimonious Model

절약형 모델(Parsimonious Model)

⚡ 하기 쉬운 실수 : **Feature의 수를 늘리는 것**



“ 좋은 모형이란, 기본적인 절약형 모형 ”

시계열 모형의 특징

☑ Parsimonious Model

절약형 모델(Parsimonious Model)



Overfitting 문제 해결 가능

- » Time-series에서 적절한 lag 수를 정하지 않으면 Overfitting 문제 야기
- » 적절한 lag수 결정시 ACF나 PACF 등을 사용해도 효과 미비

시계열 모형의 특징

☑ 모형 선택 기준

모형 선택 기준

잔차제곱합의 함수

- 비용 함수

패널티 항

- Lag수 증가시 비용이 발생하게끔 그 항을 Specify

위 기준을 가지고 Parameter를 추정하면 **최적의 래그 수** 결정 가능

시계열 모형의 특징

☒ 모형 선택 기준

Akaike's Information Criteria

Schwarz's Bayesian Information Criteria

Hannan-Quinn Information Criteria